


# Regression Models Performance Evaluation

&

Feature Importance & confusion matrix

يعرض هذا القسم نتائج تقييم نماذج الانحدار المستخدمة و مقارنتها من حيث الاداء



# KNN Regression Model

```
● print("MAE:", mae)  
  print("RMSE:", rmse)  
  print("R2:", r2)
```

[01]

..

```
MAE: 2.356940507888794  
RMSE: 15.84200668334961  
R2: 0.8552253842353821
```

قمنا بتقييم اداء نموذج KNN Regression Model ب استخدام مقاييس  $R^2$  & MAE & RMSE. أظهرت النتائج أن قيمة  $R^2$  بلغت 0.85، مما يدل على أن النموذج يفسر نسبة كبيرة من التغير في البيانات.

كما كانت قيمة MAE منخفضة، مما يعني أن متوسط الخطأ بين القيم الحقيقية والمتوقعة صغير.

بناءً على هذه النتائج تم اعتماد هذا النموذج ك نموذج نهائي للأنحدار):

# Decision Tree Regression Model

```
--- Decision Tree Results ---
```

```
MAE: 3.2700218874141735
```

```
RMSE: 25.92966236104664
```

```
R2: 0.7630377500459213
```

استخدمنا نموذج **Decision Tree Regression** بعد ما عدّلنا الباراميترز تبعته عشان نطلع بأفضل نتيجة. الهدف كان نقل الخطأ ونحسن التوقعات.

من النتائج بنلاحظ إن قيمة  $R^2$  حوالي 0.76 وهذا يعني إن النموذج بفهم جزء كبير من البيانات وبعطي توقعات منيحة.

بشكل عام، نموذج **Decision Tree** أدائه جيد وقدر يتعامل مع البيانات بشكل أفضل، خصوصًا بالعلاقات غير الخطية

# Random Forest Regression Model

```
RF MAE: 3.399033443682533
RF RMSE: 27.214095739185904
RF R2: 0.7512997559694063
```

استخدمنا نموذج Random Forest عشان أتوقع القيم، وبالنهاية طلعت معي هاي النتائج:

MAE حوالي 3.3: يعني بشكل عام التوقعات بتغلط تقريبًا 3 وحدات عن القيمة الحقيقية، وهذا إشي مقبول.

$R^2$  حوالي 0.75: هذا أهم رقم، وببديل إن النموذج فاهم تقريبًا 75% من البيانات، يعني شغله كويس.

نموذج Random Forest أداؤه منيح، وأحسن من بعض النماذج الثانية، وبنقدر نعتمد عليه بالتوقعات

# XGBoost Regression Model

[33]

```
... MAE: 3.4658944606781006  
    RMSE: 24.896343231201172  
    R2: 0.7724809050559998
```

Generate

+ Code

+ Markdown

اعتمدنا على MAE و  $R^2$  لتقييم النموذج.


قيمة MAE تقريبا 3.4: بمنخفضة نسبياً، وهذا يدل إن التوقعات قريبة من القيم الحقيقية.

كما أن قيمة  $R^2$  تقريبا 0.77 : جيدة، مما يعني **أن النموذج** قادر على تفسير جزء كبير من البيانات

# Regression Model Evaluation And Explainability


Feature Importance & confusion matrix

# KNN – Actual VS Predicted




الرسمه بتوضحلنا مقارنة بين القيم الحقيقية والقيم اللي توقعها نموذج KNN كل نقطة بتمثل قيمة حقيقية (Actual) مقابل توقع النموذج إليها (predict)


ملاحظ إن التوقعات بشكل عام قريبة من القيم الحقيقية، بس مع زيادة القيم الحقيقية بصير في فرق أكبر شوي، وهذا يعني إن أداء النموذج منيح بالقيم الصغيرة وأضعف شوي بالقيم الكبيرة



# KNN - Residuals vs Predicted

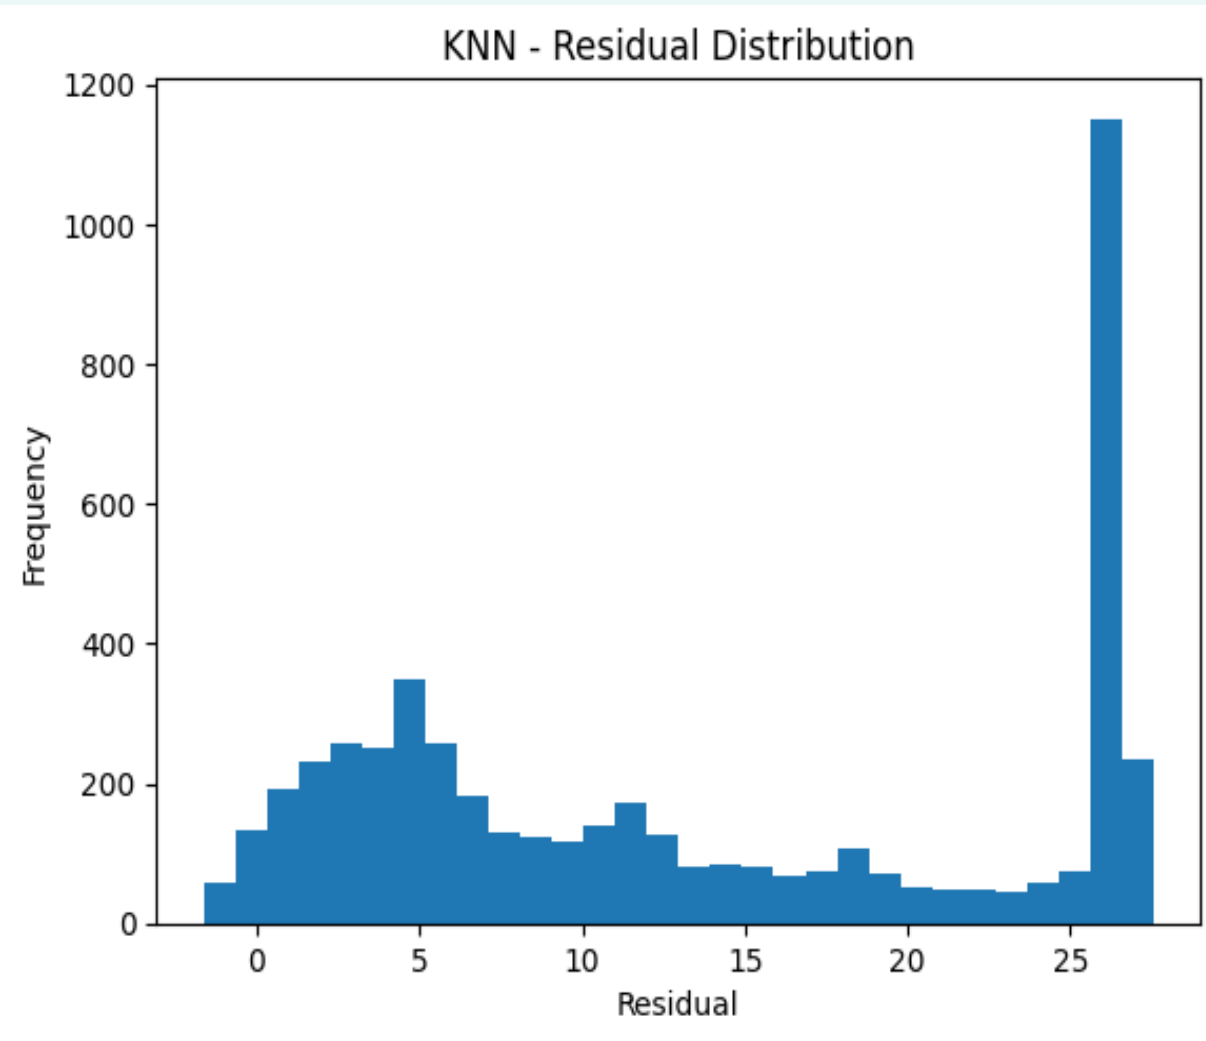


هاي الرسمة بتفرجي الفرق بين القيم المتوقعة والقيم الحقيقية بنموذج KNN لما تكون القيم المتوقعة صغيرة، بنلاحظ إنو الأخطاء قليلة وقريبة من الصفر، يعني النموذج شغله منيح بهالحالات. بس كل ما تكبر القيم، الخطأ بكبر وبصير أوضح، وهاد يعني إنو النموذج ما يكون دقيق كتير مع القيم الكبيرة. بشكل عام، زي ما تعلمنا بنموذج KNN أداءه مقبول مع القيم الصغيرة، بس دقته بتضعف لما القيم تكبر.






# KNN - Residual Distribution

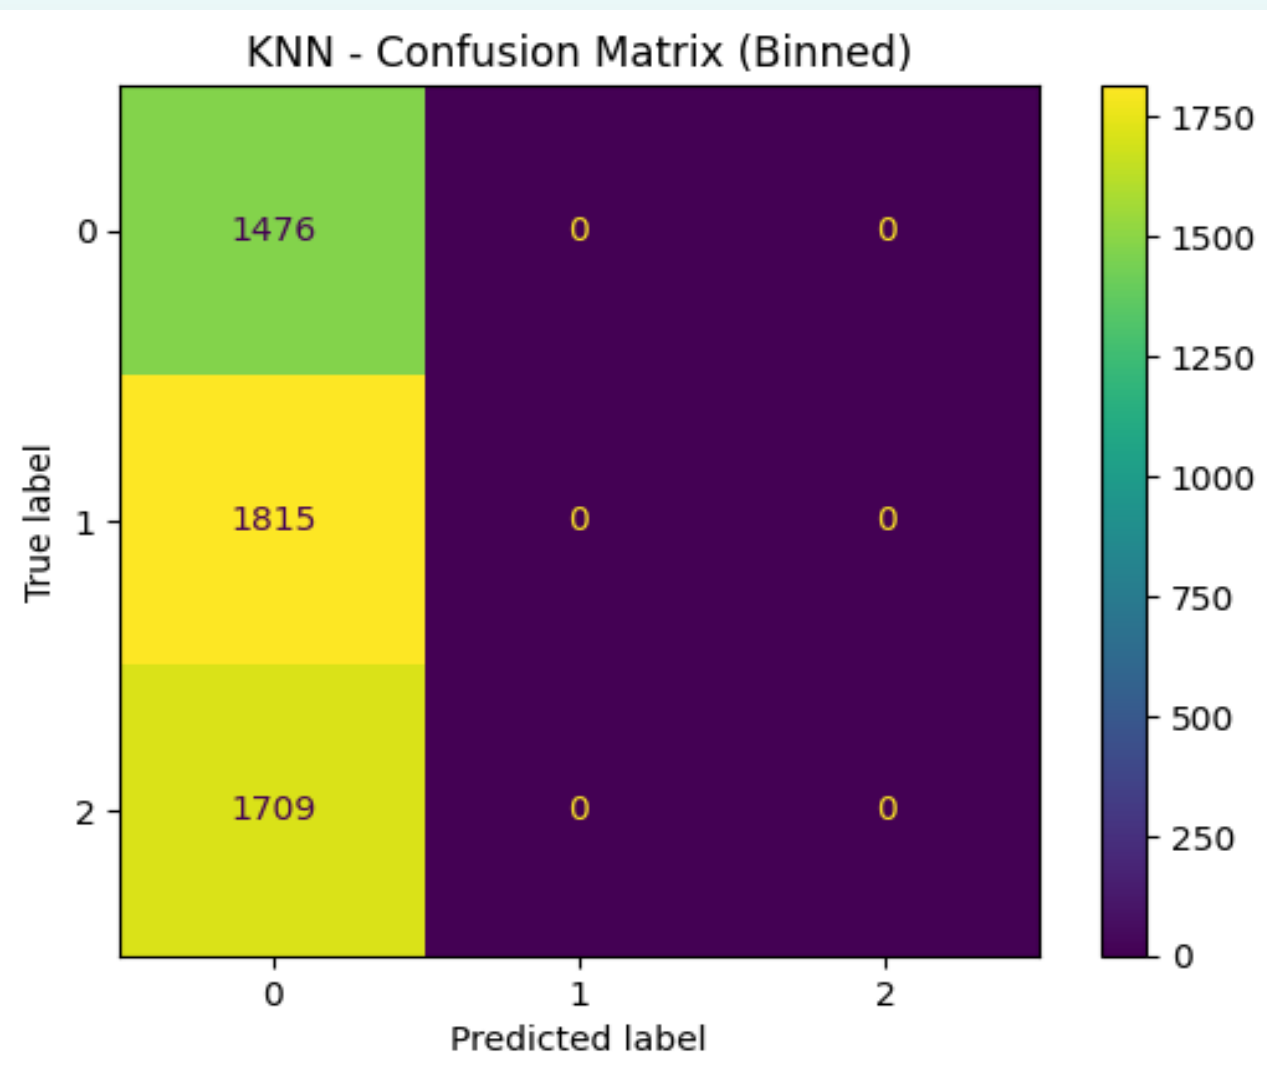


هذه الرسمة بتفرجي توزيع الأخطاء (Residuals) بنموذج KNN


يعني قديش الفرق بين القيمة الحقيقية والقيمة اللي النموذج توقعها. بنلاحظ إنه في جزء كبير من الأخطاء قريب من الصفر، وهاد إشي منيح لأنه يعني إنه النموذج غالبًا توقعاته قريبة من الحقيقة. بس بنفس الوقت في أخطاء كبيرة، خاصة بالقيم العالية، وهاد بوضح إنه النموذج أحيانًا بغلط كثير لما تكون القيم كبيرة. بشكل عام، النموذج أداءه مقبول



# KNN - Confusion Matrix (Binned)




هناك الرسمة بتوضح إنو نموذج KNN  
أغلب الوقت بتوقع نفس الفئة، حتى لو  
القيم الحقيقية كانت مختلفة. يعني  
النموذج ما قدر يفرق منيح بين الفئات،  
وخصوصًا بالقيم العالية. هاد بيدل إنو أداء  
KNN بهالتصنيف مش قوي، وبغلط لما  
البيانات تكون متنوعة




# Decision Tree - Actual vs Predicted


Decision Tree - Actual vs Predicted



بشكل عام، نموذج Decision Tree قدر يلتقط النمط العام بالبيانات ويفرق بين المستويات المختلفة للقيم، وهذا يدل إنو النموذج فاهم العلاقة الأساسية بين المتغيرات، لكنه يحتاج تحسين بسيط ليعطي توقعات أدق خاصة للقيم العالية



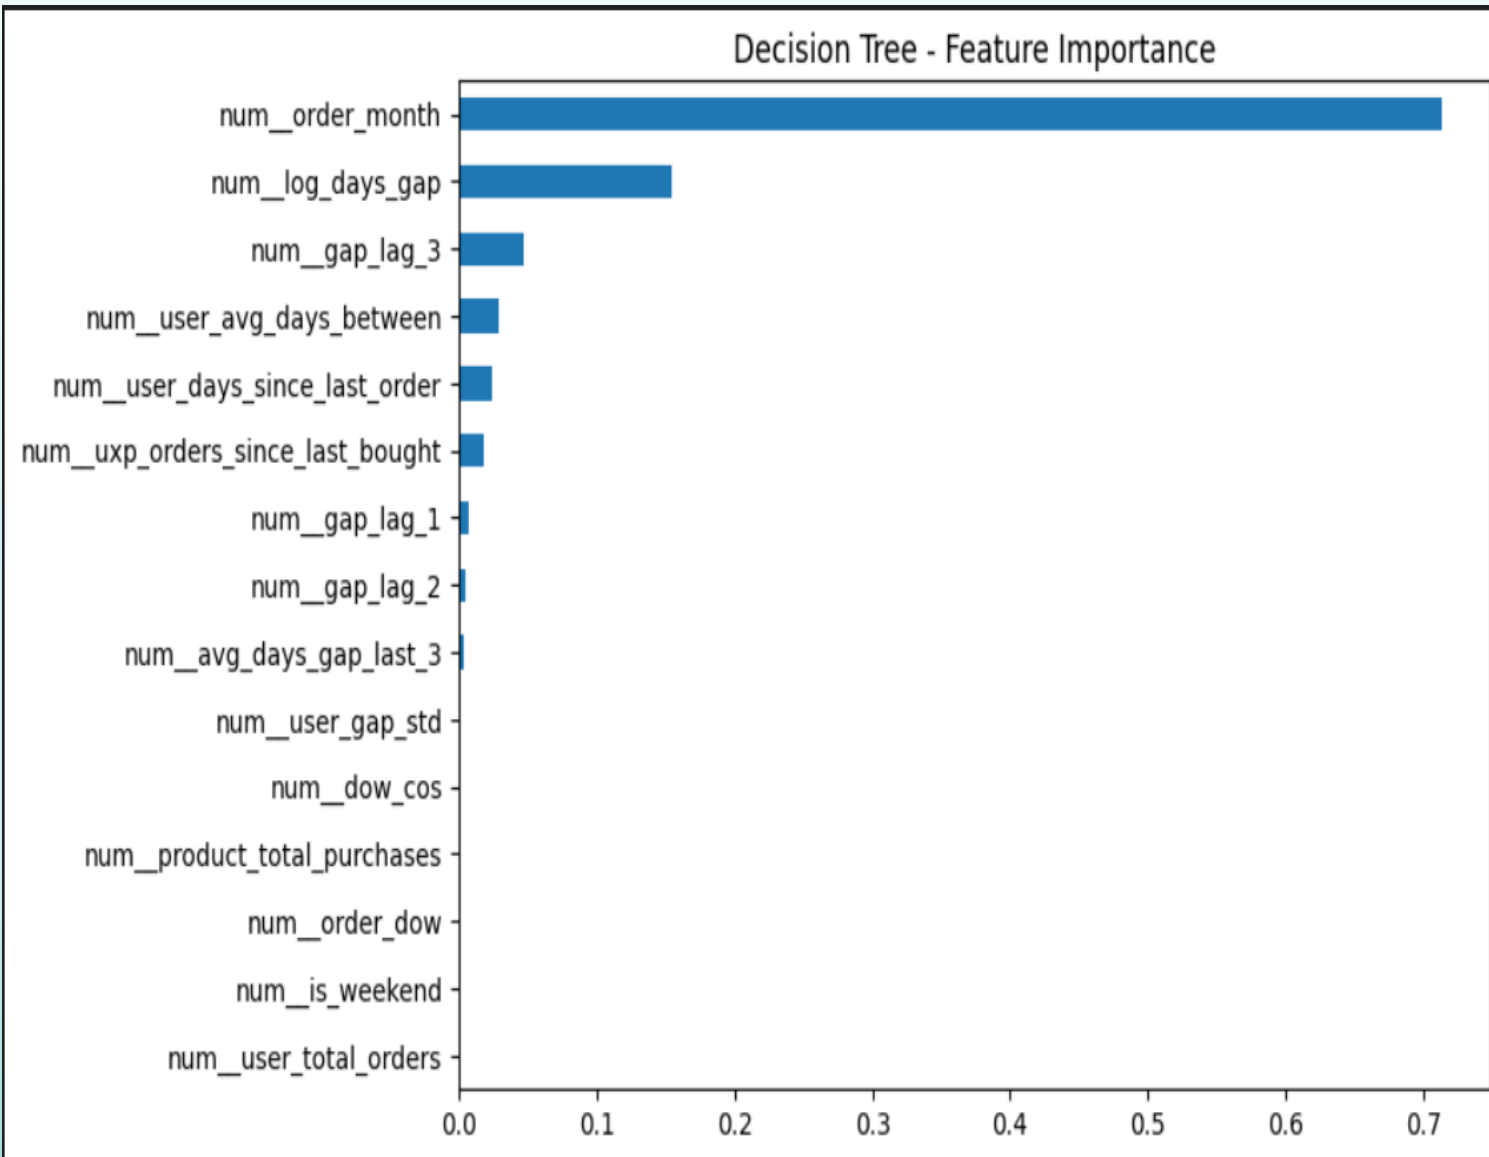
## Decision Tree - Confusion Matrix (Binned)



هاي المصفوفة بتوضح أداء نموذج Decision Tree بعد ما قسمنا القيم لفئات. بنلاحظ إنو أغلب القيم موجودة على القطر، يعني النموذج غالبًا بتوقع الفئة الصح. بس في شوية خرابطة بين الفئات، خاصة بين الفئة 0 و1، وهذا يعني إنو أحيانًا النموذج بلخبط بينهم. بشكل عام، أداء النموذج منيح، بس مش مثالي



# Decision Tree - Feature Importance



هاي الرسمة بتفرجينا أي features كان

إلها التأثير الأكبر بقرارات نموذج Decision

Tree. بنلاحظ إني NUM\_order\_month هو


أكثر إشي أثر بالنموذج، يعني وقت الطلب كان

عامل مهم بالتوقع. باقي المتغيرات تأثيرها أقل،


يعني النموذج ما اعتمد عليها كثير. بشكل عام،

النموذج برکز على الوقت وتكرار الشراء أكثر من


أي إشي ثاني




# Random Forest - Actual vs Predicted




هاي الرسمة بتفرجينا مقارنة بين القيم الحقيقية والقيم اللي توقعها نموذج Random Forest بنلاحظ إنو أغلب النقاط قريبة من بعض وعلى نفس الاتجاه، وهذا يعني إنو النموذج عم يتوقع بشكل منيح بشكل عام. كل ما كانت القيم الحقيقية أكبر، التوقعات كمان بتكبر، وهذا إشي إيجابي. طبعًا في شوية تشتت وأخطاء، بس بشكل عام أداء النموذج جيد وأحسن من النماذج الأبسط




## Random Forest - Residuals vs Predicted




## Random Forest - Residual Distribution



## Random Forest - Confusion Matrix (Binned)

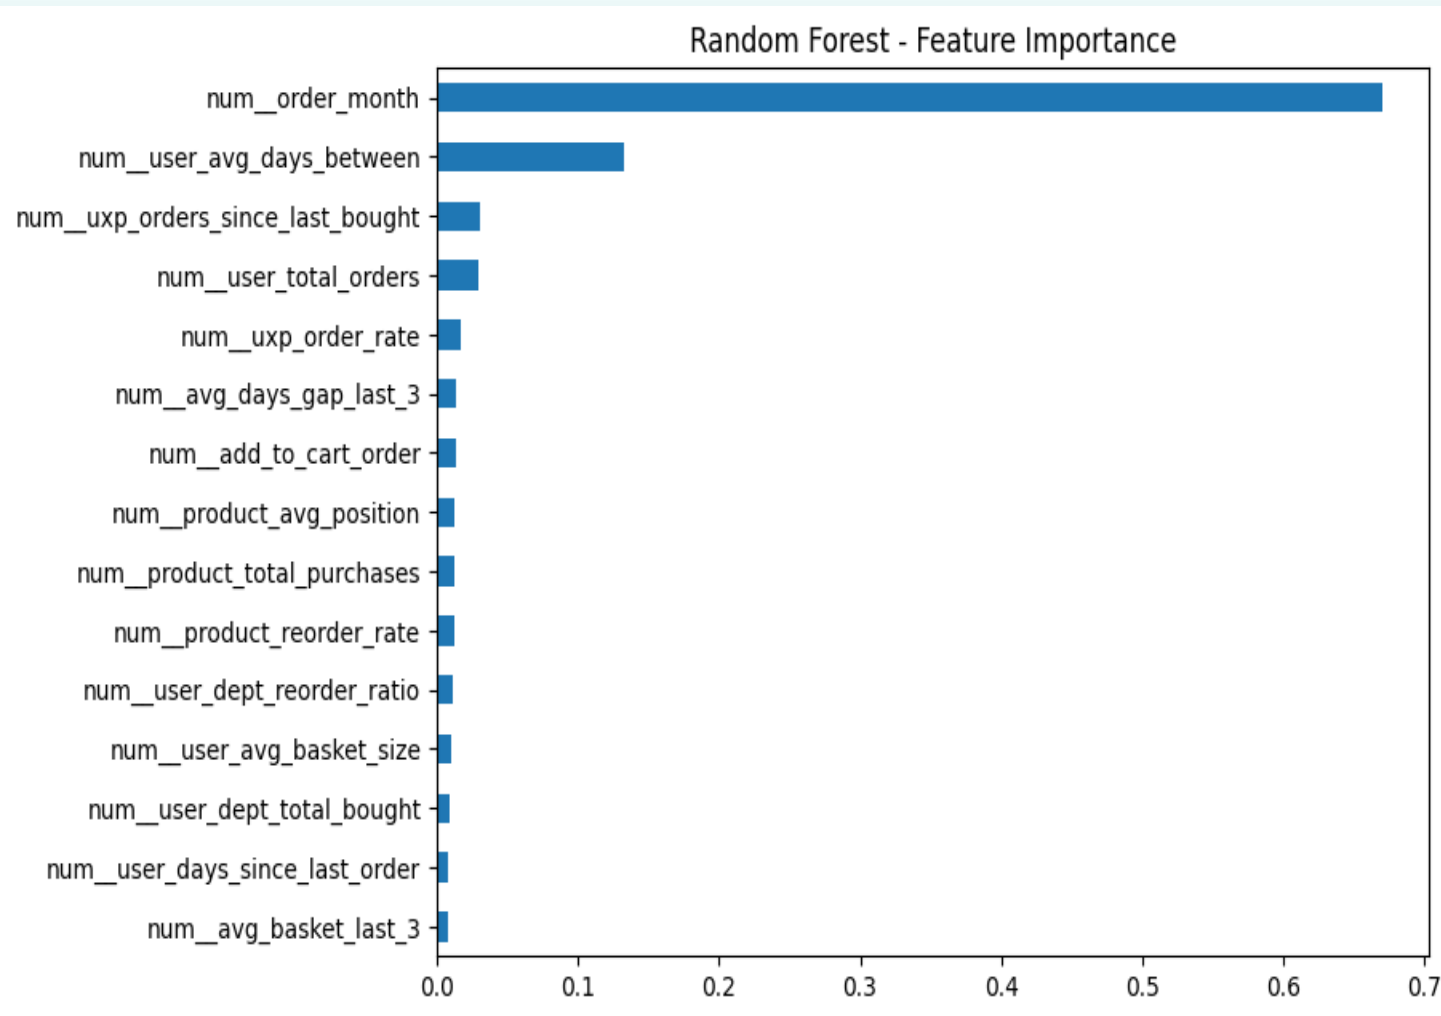


هناك الرسمة بتفرجينا ال Confusion Matrix لنموذج Random Forest بعد ما قسمنا القيم لفئات. بنلاحظ إنو أغلب القيم موجودة على القطر، يعني النموذج غالبًا بتوقع الفئة الصح. في شوية لخبطة بين الفئات القريبة من بعض، بس بشكل عام النموذج أداؤه منيح وبفرق بين الفئات بشكل أفضل من النماذج السابقة






# Random Forest - Feature Importance




هاي الرسمة بتفرجينا قديش كل متغير إله  
تأثير على توقعات نموذج Random Forest  
واضح إنو أكثر إشي بأثر هو  
num\_order\_month، يعني وقت الطلب إله  
دور كبير بالنتيجة. بعده بييجي average days  
between orders، يعني كل ما المستخدم  
بطلب بفترات قريبة أو بعيدة يفرق بالتوقع.  
باقي المتغيرات تأثيرها أقل، بس لسه إله دور  
بسيط. بشكل عام، النموذج بعتمد أكثر على  
وقت وسلوك الطلب أكثر من باقي التفاصيل



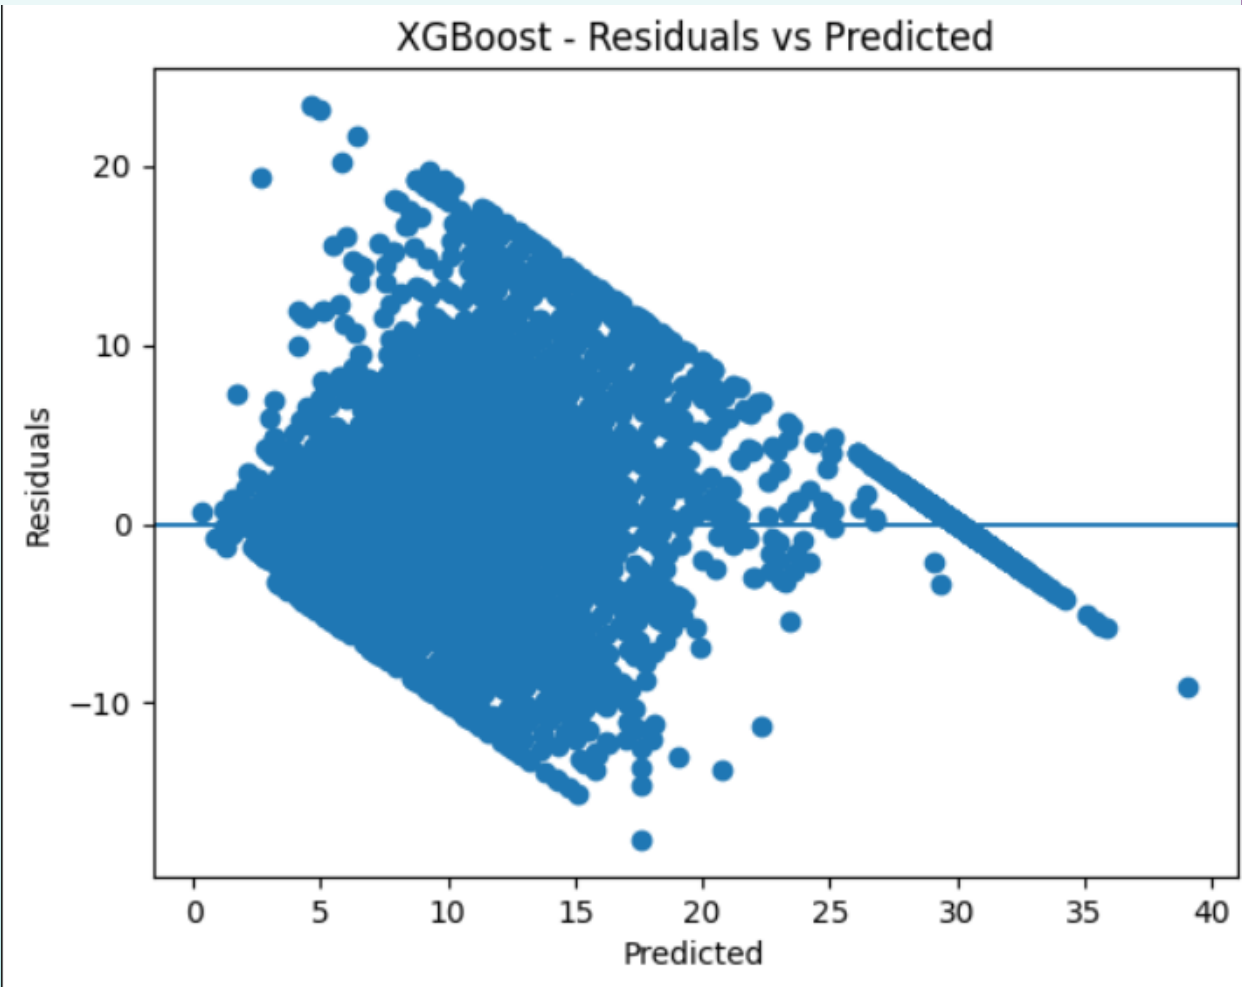
# XGBoost - Actual vs Predicted



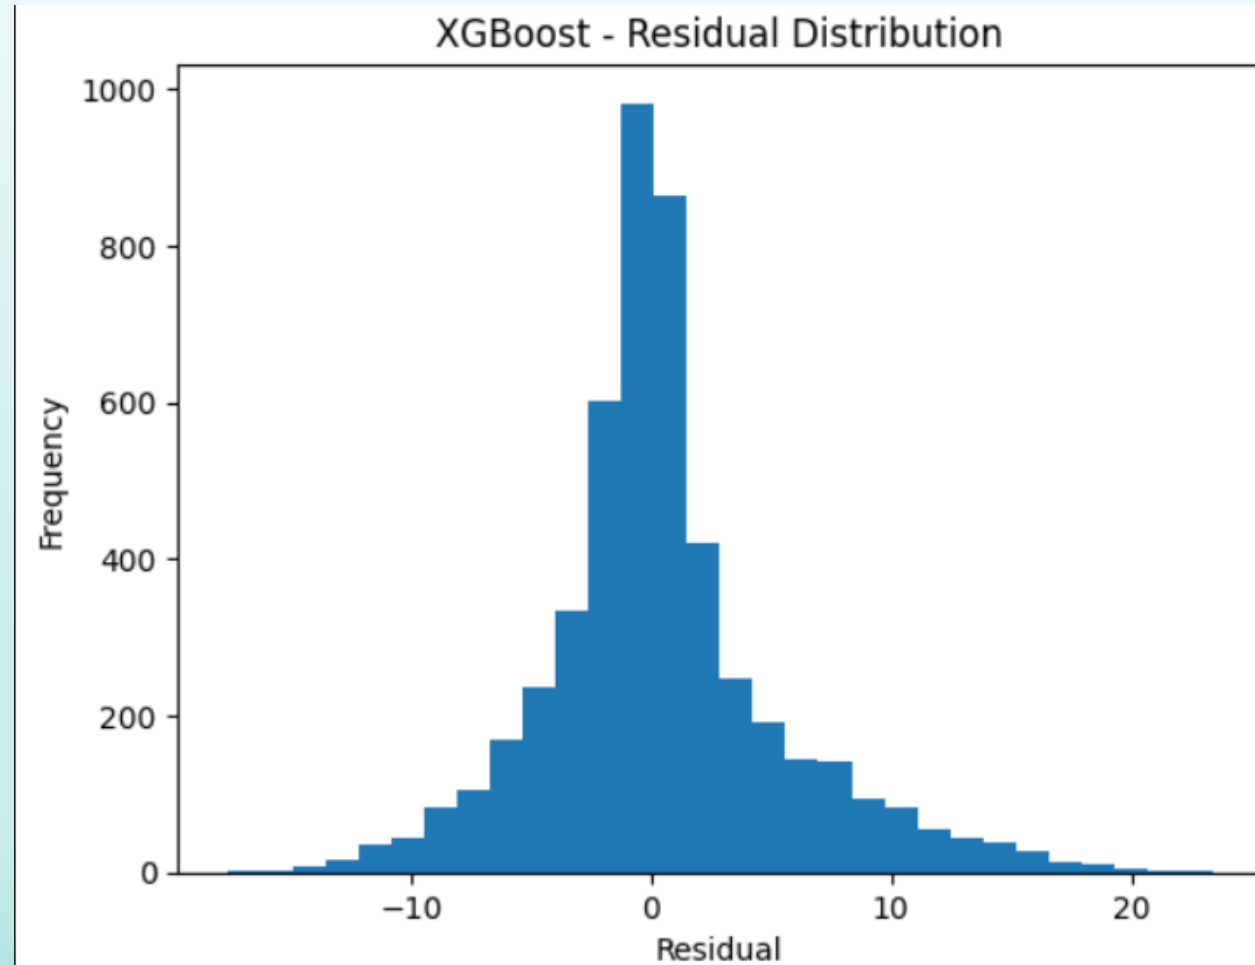
هاي الرسمة بتوضح الفرق بين القيم الحقيقية والقيم اللي توقّعها نموذج XGBoost بشكل عام بنشوف إنو التوقعات قريبة من القيم الحقيقية، خصوصًا بالقيم المتوسطة، وهذا إشي منيح. بس بالقيم العالية، في تشتّت وأحيانًا النموذج ببالغ أو بقصر بالتوقع. يعني النموذج أدائه منيح بشكل عام، بس لسه عنده صعوبة شوي مع القيم الكبيرة



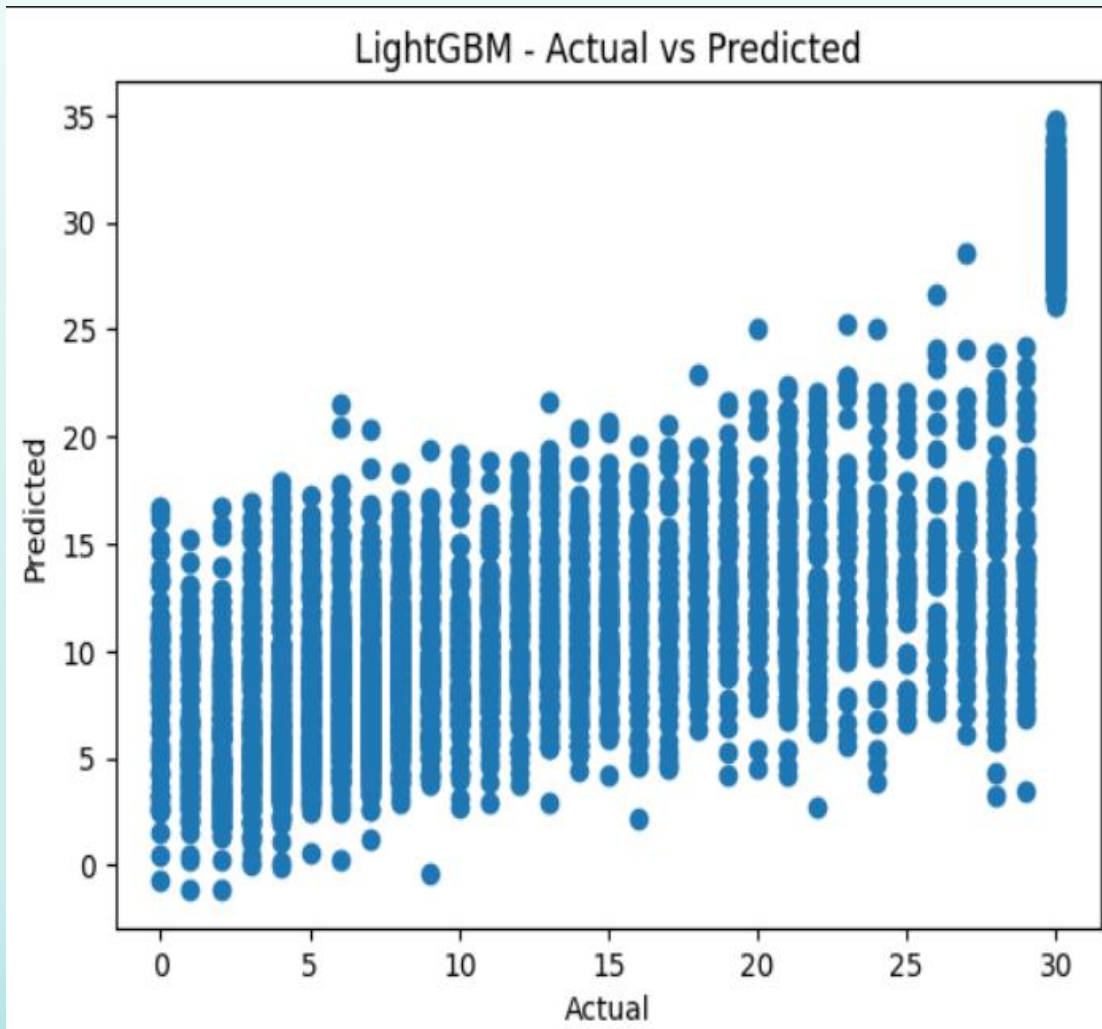
## XGBoost - Residuals vs Predicted



## XGBoost - Residual Distribution




## LightGBM - Actual vs Predicted




هاي الرسمة بتفرجي مقارنة بين القيم الحقيقية والقيم  
اللي توقّعها نموذج LightGBM


بشكل عام في علاقة واضحة بينهم، يعني كل ما القيمة  
الحقيقية تكبر، التوقع كمان بكبر، وهاد إشي منيح. التوقعات  
بالقيم المتوسطة قريبة من الحقيقة، بس بالقيم العالية في  
• تشتّت وأحيانًا النموذج ما بيمسكها بدقة. بشكل عام أداء  
النموذج منيح، بس لسه بده تحسين بالقيم الكبيرة




## LightGBM - Residuals vs Predicted



## LightGBM - Residual Distribution



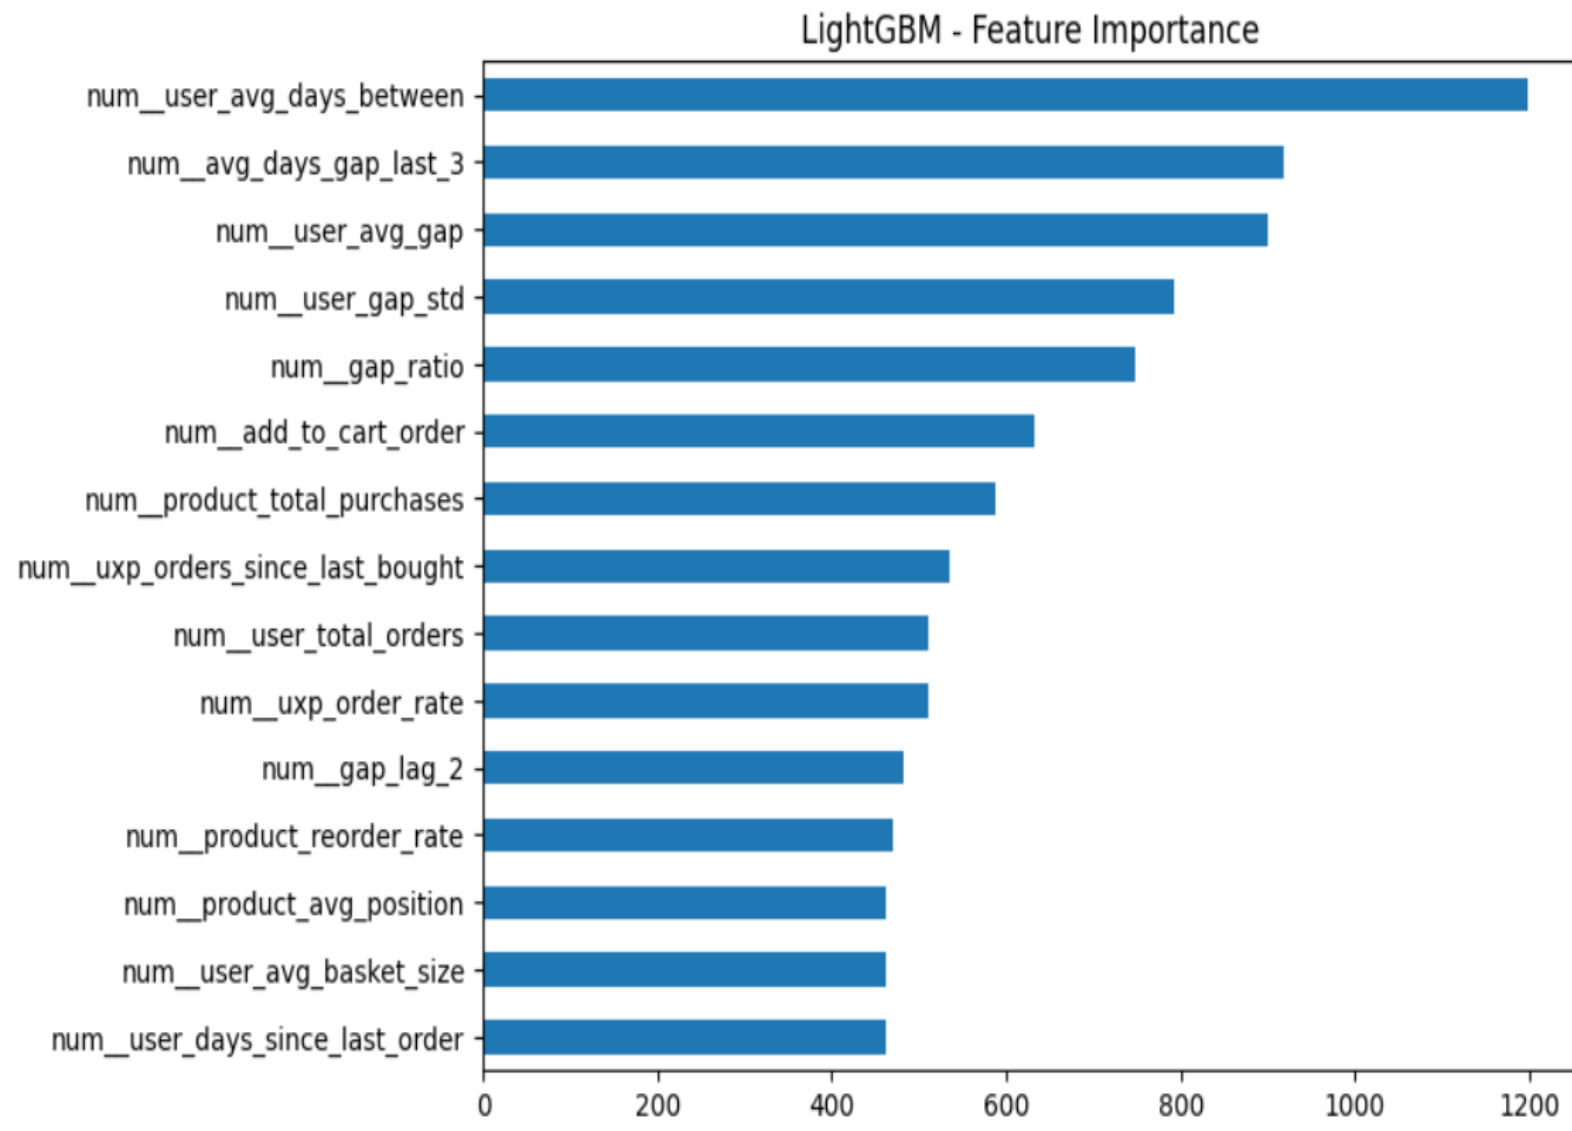
## LightGBM - Confusion Matrix (Binned)



توضح مصفوفة لنموذج LightGBM أن النموذج يحقق أداءً قوياً في تصنيف البيانات، حيث تتركز معظم القيم على القطر الرئيسي، خاصة في الفئتين (1) و(2)، مما يدل على دقة عالية في التنبؤ بهما. كما أن عدد الأخطاء بين الفئات منخفض نسبياً، خصوصاً الخلط مع الفئة (2)، وهذا يشير إلى أن النموذج قادر على التمييز بشكل جيد بين المستويات المختلفة مع نسبة خطأ

محدودة

# LightGBM - Feature Importance



هاي الرسمة بتفرجي أكثر المتغيرات اللي نموذج LightGBM اعتمد عليها بالتوقع. بنلاحظ إني عدد الأيام بين طلبات المستخدم كان الأكثر تأثير. باقي المتغيرات إلها تأثير أقل بس لسه بتساعد النموذج. يعني النموذج ركّز أكثر على سلوك المستخدم وتكرار الشراء ليطلع النتيجة

